

MuJoCo Humanoid RL MLOps

Humanoid-v5 trajectory 수집부터 PPO 학습, 시뮬레이션 검증, MLflow 실험 추적까지

Portfolio Focus

로봇 시뮬레이션 강화학습을 데이터셋/모델/실험 추적 관점으로
구성한 미니 파이프라인

Stack

MuJoCo · Gymnasium · Stable-Baselines3 PPO · PyTorch CPU ·
Parquet · MLflow

Pilsu Choi

https://github.com/pilsu-choi/mujoco_tutorial

1. 프로젝트 목표

Humanoid-v5를 기준으로 강화학습 실험 흐름을 MLOps 관점에서 재현

- MuJoCo Humanoid-v5 환경에서 전신 3D 휴머노이드 시뮬레이션 실행
- timestep 단위 데이터 수집
 - observation
 - action
 - reward
 - done transition
- Stable-Baselines3 PPO로 policy 학습 및 모델 artifact 저장
- 학습된 policy를 다시 시뮬레이터에 투입해 동작과 reward 확인
- MLflow로 아래 지표 추적
 - hyperparameter
 - reward metric
 - model/evaluation artifact

학습 목표

균형을 유지하면서 앞으로 이동하는 humanoid locomotion policy 학습

핵심 메시지


강화학습 자체와 함께 trajectory 데이터 관리, 실험 추적, 재현 가능한 평가 흐름을 구성

왜 Humanoid-v5?

전신 관절 상태와 actuator control을 다루므로 로보틱스/휴머노이드 도메인에 가장 가까운 MuJoCo benchmark

2. End-to-End Architecture

시뮬레이션 데이터 수집부터 학습/평가/추적까지 한 흐름으로 연결



수집 schema: episode_id, step, env_name, observation, action, reward, next_observation, done, policy, seed

학습 artifact: models/ppo_humanoid.zip

평가 artifact: data/eval/humanoid_evaluation_rollout.parquet

실험 추적: mujoco-ppo experiment 내 train/eval run 저장

3. Humanoid Trajectory 수집

Random policy로 먼저 transition 데이터를 Parquet dataset으로 저장

```
Problems Output Debug Console Terminal
● pilsu@DESKTOP-UEHP5NV:~/resume/mujoco_tutorial$ uv run python examples/collect_rollout.py --episodes 3 --out data/rollouts/humanoid_random_policy.parquet
Wrote 106 transitions from 3 episodes to data/rollouts/humanoid_random_policy.parquet
● pilsu@DESKTOP-UEHP5NV:~/resume/mujoco_tutorial$ uv run python - <<'PY'
import pandas as pd
df = pd.read_parquet("data/rollouts/humanoid_random_policy.parquet")
print(df.head())
print(df.columns.tolist())
print("observation_dim:", len(df.iloc[0]["observation"]))
print("action_dim:", len(df.iloc[0]["action"]))
PY
  episode_id  step  env_name  ...  done  policy  seed
0           0     0  Humanoid-v5  ...  False  random   42
1           0     1  Humanoid-v5  ...  False  random   42
2           0     2  Humanoid-v5  ...  False  random   42
3           0     3  Humanoid-v5  ...  False  random   42
4           0     4  Humanoid-v5  ...  False  random   42

[5 rows x 10 columns]
['episode_id', 'step', 'env_name', 'observation', 'action', 'reward', 'next_observation', 'done', 'policy', 'seed']
observation_dim: 348
action_dim: 17
○ pilsu@DESKTOP-UEHP5NV:~/resume/mujoco_tutorial$
```

수집 데이터 의미



observation_dim=348: 몸통/전신 관절 상태 및 속도 계열
action_dim=17: 각 actuator에 전달되는 control signal

핵심 포인트

환경이 Hopper/Walker/Humanoid로 바뀌어도 transition schema는 유지되고 vector dimension만 달라지는 구조

4. MuJoCo Humanoid 시뮬레이터 확인

학습된 policy 또는 rollout을 실제 viewer에서 시각적으로 검증



Humanoid-v5는 전신 3D 관절과 actuator를 가진 locomotion benchmark
정량 metric뿐 아니라 viewer로 policy 동작을 직접 확인해 데모 가능

5. PPO 학습 로그

Stable-Baselines3 PPO가 reward를 최대화하도록 policy network를 업데이트

```
pi@supernode05:~/workspace/mujoco_tutorial$ uv run python examples/train_ppo.py --timesteps 10000
/home/pi@supernode05:~/workspace/mujoco_tutorial/.venv/lib/python3.11/site-packages/mlflow/tracking/_tracking_service/utils.py:184: FutureWarning: The filesystem tracking backend (e.g., '~/mlruns') is deprecated as of February 2026. Consider transitioning to a database backend (e.g., 'sqlite:///mlflow.db') to take advantage of the latest mlflow features. See https://mlflow.org/docs/latest/self-hosting/migrate-from-file-store for migration guidance.
  return FileStore(store_uri, store_uri)
Using cpu device
Wrapping the env with a 'Monitor' wrapper
Wrapping the env in a DummyVecEnv.

rollout/
  ep_len_mean      21.4
  ep_rev_mean      95.4
  time/
    fps            2082
    iterations      1
    time_elapsed    0
    total_timesteps 2048
-----
rollout/
  ep_len_mean      22
  ep_rev_mean      98.3
  time/
    fps            15.44
    iterations      2
    time_elapsed    2
    total_timesteps 4096
train/
  approx_kl         0.020185314
  clip_fraction     0.225
  clip_range        0.2
  entropy_loss      -24.1
  explained_variance 0.000616
  learning_rate     0.0003
  loss              323
  n_updates         10
  policy_gradient_loss -0.0507
  std               0.998
  value_loss        1.18e+03
-----
rollout/
  ep_len_mean      22.5
  ep_rev_mean      101
  time/
    fps            1457
    iterations      3
    time_elapsed    4
    total_timesteps 6144
train/
  approx_kl         0.025363263
  clip_fraction     0.258
  clip_range        0.2
  entropy_loss      -24.1
  explained_variance 0.0238
  learning_rate     0.0003
  loss              392
  n_updates         20
  policy_gradient_loss -0.0701
  std               0.995
  value_loss        917
-----
rollout/
  ep_len_mean      22.9
  ep_rev_mean      107
  time/
    fps            1190
    iterations      5
    time_elapsed    6
    total_timesteps 10240
train/
  approx_kl         0.03332686
  clip_fraction     0.248
  clip_range        0.2
  entropy_loss      -24
  explained_variance 0.0376
  learning_rate     0.0003
  loss              249
  n_updates         30
  policy_gradient_loss -0.0950
  std               0.994
  value_loss        707
-----
/home/pi@supernode05:~/workspace/mujoco_tutorial/.venv/lib/python3.11/site-packages/stable_baselines3/common/evaluation.py:71: UserWarning: Evaluation environment is not wrapped with a "Monitor" wrapper. This may result in reporting modified episode lengths and rewards, if other wrappers happen to modify these. Consider wrapping
  warnings.warn(
Run ID: 86261a1b-4b44-4026-b056-b4c0b1c27f
Save the model to model_zoo/mujoco_ppo
Evaluation time: 0.000000s
pi@supernode05:~/workspace/mujoco_tutorial$
```

6. 학습된 Policy 평가

저장된 PPO 모델을 로드해 재시뮬레이션하고 evaluation trajectory 저장

```
pilsu@DESKTOP-UEHP5NV:~/resume/mujoco_tutorial$ uv run python examples/watch_policy.py --model-path models/ppo_humanoid.zip
Wrapping the env with a `Monitor` wrapper
Wrapping the env in a DummyVecEnv.
Episode 0: reward=350.00
Episode 1: reward=273.82
Episode 2: reward=289.36
pilsu@DESKTOP-UEHP5NV:~/resume/mujoco_tutorial$
```

```
pilsu@DESKTOP-UEHP5NV:~/resume/mujoco_tutorial$ uv run python examples/evaluate_policy.py --model-path models/ppo_humanoid.zip
/home/pilsu/resume/mujoco_tutorial/.venv/lib/python3.11/site-packages/mlflow/tracking/_tracking_service/utils.py:134: FutureWarning: The filesystem tracking backend (e.g., './mlruns') is deprecated as of February 2026. Consider transitioning to a database backend (e.g., 'sqlite:///mlflow.db') to take advantage of the latest MLflow features. See https://mlflow.org/docs/latest/self-hosting/migrate-from-file-store for migration guidance.
  return FileStore(store_uri, store_uri)
Wrapping the env with a `Monitor` wrapper
Wrapping the env in a DummyVecEnv.
Run ID: c9c6aa04110d4334a331f3e04558f564
Wrote 283 evaluation transitions to data/eval/humanoid_evaluation_rollout.parquet
Evaluation reward: mean=283.95, std=42.76
pilsu@DESKTOP-UEHP5NV:~/resume/mujoco_tutorial$
```

평가 결과

Episode reward와 eval_mean_reward를 기록해 학습된 policy의 성능을 비교 가능하게 구성

데이터 재사용

evaluation rollout도 Parquet으로 저장해 후속 분석, 시각화, MLflow artifact 등록에 사용

7. MLflow 실험 추적

학습/평가 run을 experiment 단위로 기록하고 metrics와 artifact를 관리

mlflow
3.11.1

GenAI Model training

Home

Experiments

Prompts

AI Gateway

Experiments

Create Compare Delete

Search experiments

Tag

Name	Time created	Last modified	Description	Tags
☐ mujoco-ppo	05/03/2026, 06:59:57 AM	05/03/2026, 06:59:57 AM	-	
☐ Default	05/03/2026, 06:59:57 AM	05/03/2026, 06:59:57 AM	-	

mlflow
3.11.1

GenAI Model training

mujoco-ppo

Overview

Observability

Traces

Sessions

Evaluation

Judges

Datasets

Evaluation runs

Prompts & versions

Prompts

Agent versions

AI Gateway

Experiments > mujoco-ppo

Evaluation runs

metrics.rmse < 1 and params.model = "tree"

Columns Group by Actions

Run Name	Status	Created at	Dataset	episode_reward	eval_std_reward	eval_mean_reward	std_reward	mean_reward
☐ eval-Humanoid-v5	✓	just now	-	237.31547846464125	42.764202757432514	263.9521038585643	-	-
☐ ppo-Humanoid-v5-10000	✓	just now	-	-	-	-	44.866687389600068	257.41289373636243
☐ eval-InvertedPendulum-v5	✓	just now	-	114	22.618576436195095	122	-	-
☐ ppo-InvertedPendulum-v5-10000	✓	just now	-	-	-	-	22.569005294872877	122.2
☐ eval-InvertedPendulum-v5	✓	just now	-	34	3.5	30.5	-	-
☐ ppo-InvertedPendulum-v5-1000	✓	just now	-	-	-	-	4.019950248448357	27.2

8. 구현 구성

각 단계는 독립 실행 가능한 Python script로 분리

collect_rollout.py

Humanoid-v5 환경에서 random policy transition을 수집하고 Parquet으로 저장

train_ppo.py

PPO 학습, mean_reward 평가, model artifact 저장, MLflow train run 기록

evaluate_policy.py

저장된 모델을 로드해 evaluation rollout 생성 및 MLflow eval run 기록

watch_policy.py

render_mode=human으로 MuJoCo viewer에서 policy 실행 화면 확인

README.md

setup, 수집, 학습, 평가, MLflow UI 실행 명령 문서화

CPU PyTorch 기준으로 WSL에서도 재현 가능한 최소 환경 구성

Humanoid-v5는 짧은 timesteps로 demo, 긴 timesteps로 reward curve 확장 가능
향후 Airflow/Kubeflow orchestration 또는 DVC dataset versioning과 연결 가능

9. 요약 및 확장 방향

강화학습 실험을 MLOps 관점으로 운영 가능하게 만드는 첫 단계

MuJoCo Humanoid-v5에서 전신 3D 로봇 locomotion 데이터를 수집

PPO policy 학습과 evaluation을 분리해 재현 가능한 실험 흐름 구성

MLflow로 hyperparameter, reward metric, model/evaluation artifact 추적

Viewer 캡처와 reward 로그로 정성/정량 검증 모두 제시 가능

Next Step 1

학습 시간을 늘려 reward curve 개선 및 best checkpoint 비교

Next Step 2

rollout dataset을 DVC/MinIO로 버전 관리해 기존 Humanoid Data Factory PoC와 연결

Next Step 3

Airflow DAG로 collect → train → evaluate → register pipeline orchestration

핵심 포인트

로봇 시뮬레이션/강화학습을 단순 실행이 아니라 데이터, 모델, 실험 추적 단위로 관리함